

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

ĐẠI HỌC BÁCH KHOA HỒ CHÍ MINH



Course: Đồ Án Tổng Hợp - Hướng Trí Tuệ Nhân Tạo

Assignment Report

Chart Question And Answering

Optimizing Long-chain Reasoning for Chart Question Answering with
Chain-of-Thought and Reinforcement Learning

Instructor: Mai Xuân Toàn, Trần Tuấn Anh, Huỳnh Văn Thống, Trần Hồng Tài

STT	Họ tên SV	MSSV
1	Trần Đỗ Đức Phát	2312596
2	Phan Đức Nhã	2312410
3	Phan Thành Long	2211891

14th December 2025

Mục lục

1	Giới thiệu chung	1
1.1	Định nghĩa bài toán Chart Question Answering	1
1.2	Thách thức hiện tại	1
1.3	Mục tiêu và Phương pháp tiếp cận	2
1.4	Đóng góp chính của đồ án	2
2	Tổng quan tài liệu và Cơ sở lý thuyết	3
2.1	Các nghiên cứu liên quan	3
2.1.1	Phương pháp dựa trên Vision-Language Pre-training	3
2.1.2	Phương pháp sử dụng Chain-of-Thought (CoT)	3
2.2	Mô hình nền tảng Qwen-VL	3
2.3	Chain-of-Thought Reasoning	4
2.3.1	Chain-of-Thought trong LLMs	4
2.3.2	CoT trong Đa phương thức	5
2.4	Các kỹ thuật Huấn luyện và Tối ưu hóa	5
2.4.1	Tinh chỉnh thích ứng hạng thấp lượng tử hóa (QLoRA)	5
2.4.2	Supervised Fine-Tuning (SFT)	5
2.4.3	Group Relative Policy Optimization (GRPO)	5
3	Chiến lược huấn luyện	6
3.1	Giai đoạn 1: Khởi tạo năng lực suy luận - SFT Stage	6
3.1.1	Quy trình tổng hợp dữ liệu ChartThink	6
3.1.2	Huấn luyện tinh chỉnh	7
3.2	Giai đoạn 2: Tối ưu hóa suy luận - RL Stage	7
3.2.1	Thiết kế Hàm phần thưởng	7
3.2.2	Phần thưởng tổng - R_{total}	8
3.2.3	Hàm mục tiêu huấn luyện	8
4	Thực nghiệm và đánh giá mô hình	10
4.1	Thiết lập thực nghiệm	10
4.1.1	Bộ dữ liệu	10
4.1.2	Thước đo đánh giá	10
4.1.3	Các mô hình cơ sở	10
4.1.4	Chi tiết triển khai	11
4.2	Kết quả	12
4.3	Case Study	13
4.3.1	Tình huống 1: Kích hoạt tư duy toán học (Math & Logic Activation)	13
4.3.2	Tình huống 2: Định vị thị giác trong môi trường nhiễu (Visual Grounding)	13
5	Kết luận	14
5.1	Tổng kết các đóng góp chính	14
5.2	Hạn chế tồn tại	15
5.3	Hướng phát triển trong tương lai	15

Danh mục Hình ảnh

1	Ví dụ câu hỏi ngôn ngữ tự nhiên trong bài toán Chart Question Answering.	1
2	Kiến trúc tổng quát của Qwen3-VL	4
3	Training Pipeline and Reward Design cho mô hình ChartN	9
4	So sánh khả năng kích hoạt tư duy toán học giữa mô hình Base và ChartN.	13
5	So sánh khả năng định vị thị giác giữa mô hình Base và ChartN trên biểu đồ kết hợp.	14

Danh mục Bảng biểu

1	So sánh độ chính xác (Accuracy %) theo từng loại câu hỏi trên tập dữ liệu CHARTQAPRO.	12
---	---	----

Tóm tắt


Các mô hình ngôn ngữ lớn đã thể hiện khả năng lý luận đáng kể thông qua việc suy luận theo chuỗi dài trước khi đưa ra phản hồi. Tuy nhiên, khả năng này khi đưa sang các nhiệm vụ lý luận hình ảnh vẫn là một thách thức chưa được giải quyết. Các phương pháp lý luận đa phương tiện hiện có thường chuyển nhiệm vụ lý luận hình ảnh thành nhiệm vụ lý luận văn bản thông qua một số lần chuyển đổi từ hình ảnh sang văn bản, thường gây ra mất thông tin và các ngữ nghĩa quan trọng được xuất hiện trong các hình ảnh trực quan, đặc biệt là đối với những câu hỏi như kiểu biểu đồ, thường đòi hỏi thông tin từ hình ảnh một cách chi tiết. Để cải thiện vấn đề này, nhóm hiện thực ý tưởng ChartN dựa trên ý tưởng ChartReasoner, một mô hình được thiết kế để cho phép lý luận chính xác và có thể giải thích đối với các biểu đồ.

Nhóm đã thực hiện một quy trình tổng hợp dữ liệu lý luận biểu đồ, tận dụng mô hình đã được huấn luyện trước để tự động và có khả năng mở rộng tạo ra các bước suy luận biểu đồ và sử dụng quy trình kiểm tra để lọc ra các mẫu chất lượng thấp. Cuối cùng, nhóm huấn luyện mô hình đa phương thức (multimodal model) bằng cách kết hợp supervised fine-tuning và reinforcement learning dựa trên dữ liệu suy luận biểu đồ đã được tổng hợp trước đó và kết quả thực nghiệm trên năm loại câu hỏi trên bộ dữ liệu chuẩn công khai chứng minh rõ ràng hiệu quả của ChartN được đề xuất. Nó có thể cải thiện được khả năng suy luận của mô hình nhỏ, tăng khả năng bảo toàn các chi tiết ban đầu của biểu đồ, tiếp cận hiệu suất của các mô hình có tham số lớn hơn nhiều lần.

1 Giới thiệu chung

1.1 Định nghĩa bài toán Chart Question Answering

Bài toán Chart Question Answering - ChartQA là một nhánh quan trọng của lĩnh vực Multimodal Question Answering. Trong đó, mô hình tiếp nhận đầu vào gồm một hình ảnh biểu đồ và một câu hỏi dạng văn bản. Nhiệm vụ cốt lõi của mô hình là thấu hiểu cấu trúc và nội dung biểu đồ, trích xuất các giá trị số được mã hóa (như chiều cao cột, tọa độ điểm, phần trăm), đồng thời thực hiện suy luận định lượng để đưa ra câu trả lời chính xác. ChartQA đòi hỏi sự kết hợp chặt chẽ giữa khả năng phân tích hình ảnh của thị giác máy tính và khả năng hiểu ngôn ngữ tự nhiên của các mô hình NLP. So với các bài toán QA văn bản truyền thống, ChartQA phức tạp hơn do thông tin được biểu diễn dưới dạng trực quan, buộc mô hình phải giải mã chính xác mối tương quan giữa các thành phần như trục, nhãn, màu sắc, chú giải (legend) và dữ liệu, sau đó thực hiện suy luận logic để tìm ra đáp án.



Hình 1: Ví dụ câu hỏi ngôn ngữ tự nhiên trong bài toán Chart Question Answering.

1.2 Thách thức hiện tại

Mặc dù các mô hình đa phương thức đã đạt được nhiều tiến bộ, bài toán ChartQA vẫn đối mặt với những thách thức đáng kể.

Thứ nhất, biểu đồ là dạng dữ liệu trực quan đặc thù, nơi thông tin không hiện diện dưới dạng văn bản tường minh mà được mã hóa qua các yếu tố thị giác như vị trí, độ dài, màu sắc, tỉ lệ và kí hiệu. Việc trích xuất chính xác giá trị số từ các yếu tố này yêu cầu mô hình phải có khả năng phân tích thị giác tinh vi và nắm bắt được quy ước biểu diễn của từng loại biểu đồ.

Thứ hai, tính nhiễu và sự phức tạp trong hiển thị. Biểu đồ thực tế thường chứa nhiều thành phần như tiêu đề, trục, nhãn dữ liệu, chú giải, đường lưới... Các thành phần này có thể bị mờ,

chồng chéo, cắt xén hoặc có phong cách thiết kế đa dạng, gây khó khăn lớn cho mô hình trong việc nhận dạng và liên kết thông tin.

Thứ ba, yêu cầu về suy luận định lượng (quantitative reasoning). Sau khi trích xuất dữ liệu, mô hình phải thực hiện các phép toán như so sánh, tính tổng, tính chênh lệch hoặc lập luận đa bước. Đây là rào cản lớn so với QA văn bản vì dữ liệu không có sẵn dưới dạng câu chữ mà phải được suy luận từ các đặc trưng thị giác.

Cuối cùng, sự đa dạng của các loại biểu đồ (bar chart, line chart, pie chart, scatter plot, stacked chart, radar chart...) cùng sự biến thiên về bố cục khiến khả năng tổng quát hóa của mô hình bị hạn chế. Những yếu tố này biến ChartQA thành một bài toán thách thức, đòi hỏi sự tích hợp hiệu quả giữa năng lực nhận thức thị giác và tư duy logic để đạt hiệu năng cao.

1.3 Mục tiêu và Phương pháp tiếp cận

Mục tiêu của đề án là xây dựng một mô hình ChartQA có khả năng suy luận chuyên sâu, khắc phục hạn chế về suy luận nông (shallow reasoning) của các phương pháp trước đây. Để hiện thực hóa mục tiêu này, nhóm tác giả đề xuất quy trình phát triển mô hình gồm ba giai đoạn:

- **Giai đoạn 1: Tổng hợp dữ liệu suy luận (Data Synthesis).** Sử dụng các Mô hình Ngôn ngữ Lớn (LLM) tiên tiến (như Gemini, GPT) để sinh ra tập dữ liệu *ChartThink*. Dựa trên 2000 bộ câu hỏi và hình ảnh từ tập dữ liệu ChartQA gốc, tập dữ liệu mới này không chỉ chứa câu hỏi và câu trả lời mà còn bổ sung các chuỗi suy luận chi tiết (Chain-of-Thought - CoT), giúp mô hình học được quy trình tư duy từng bước.
- **Giai đoạn 2: Tinh chỉnh có giám sát (Supervised Fine-Tuning - SFT).** Huấn luyện mô hình nền tảng **Qwen3-VL-Instruct** dựa trên tập dữ liệu ChartThink vừa tổng hợp. Giai đoạn này giúp mô hình hình thành khả năng hiểu biểu đồ và thực hiện các bước suy luận logic cơ bản dựa trên các mẫu dữ liệu chất lượng cao.
- **Giai đoạn 3: Tối ưu hóa bằng Học tăng cường (Reinforcement Learning).** Áp dụng thuật toán GRPO (Group Relative Policy Optimization) để tiếp tục tinh chỉnh mô hình sau bước SFT. Quá trình này giúp củng cố khả năng suy luận, giảm thiểu hiện tượng ảo giác (hallucination) và nâng cao độ chính xác tổng thể thông qua cơ chế phần thưởng (reward) dựa trên quy tắc.

Thông qua đề án, nhóm nghiên cứu củng cố nền tảng kiến thức về xử lý ảnh, NLP, học sâu đa phương thức, đồng thời nắm vững quy trình triển khai một hệ thống hỏi–đáp phức tạp trong thực tế.

1.4 Đóng góp chính của đề án

Lấy cảm hứng từ kiến trúc ChartReasoner và các nghiên cứu tiên tiến về khả năng suy luận của LLM, đề án tập trung giải quyết các hạn chế của các mô hình ChartQA hiện tại thông qua các đóng góp cụ thể sau:

- **Xây dựng quy trình tổng hợp dữ liệu suy luận:** Nhóm đề xuất quy trình tạo sinh dữ liệu ChartThink, tích hợp chuỗi suy luận từng bước (Chain-of-Thought) thay vì chỉ có cặp

câu hỏi-đáp án đơn thuần. Điều này giúp chuyển đổi bài toán từ "nhận dạng mẫu" sang "tư duy logic".

- **Triển khai kiến trúc huấn luyện tối ưu trên tài nguyên hạn chế:** Áp dụng thành công kỹ thuật tinh chỉnh tham số hiệu quả (PEFT/LoRA) kết hợp với lượng tử hóa (QLoRA) trên mô hình nền tảng Qwen-VL, chứng minh tính khả thi của việc triển khai các mô hình đa phương thức lớn (MLLMs) trong môi trường local.
- **Nâng cao khả năng suy luận bằng Học tăng cường (RL):** Tích hợp thuật toán GRPO để tinh chỉnh mô hình sau giai đoạn SFT. Khác với các phương pháp truyền thống, việc áp dụng RL giúp mô hình giảm thiểu ảo giác và tạo ra các câu trả lời có tính giải thích cao, đặc biệt trong các tác vụ đòi hỏi tính toán số học phức tạp trên biểu đồ.

2 Tổng quan tài liệu và Cơ sở lý thuyết

2.1 Các nghiên cứu liên quan

Các phương pháp giải quyết bài toán ChartQA hiện nay có thể được chia thành hai nhóm chính:

2.1.1 Phương pháp dựa trên Vision-Language Pre-training

Các mô hình như ChartLlama, MatCha, và UniChart tập trung vào việc huấn luyện trước (pre-training) trên lượng lớn dữ liệu biểu đồ để học các đặc trưng thị giác.

- **Ưu điểm:** Khả năng nhận diện thành phần biểu đồ tốt.
- **Hạn chế:** Thường gặp khó khăn trong các tác vụ suy luận logic phức tạp hoặc tính toán số học do thiếu quy trình huấn luyện chuyên sâu về tư duy (reasoning).

2.1.2 Phương pháp sử dụng Chain-of-Thought (CoT)

Gần đây, việc áp dụng CoT vào các mô hình đa phương thức (như ChartVLM, ChartAst) đã cho thấy sự cải thiện đáng kể. Các phương pháp này khuyến khích mô hình sinh ra các bước giải thích trước khi đưa ra đáp án.


- **Hạn chế tồn tại:** Phần lớn các nghiên cứu chỉ dừng lại ở việc tinh chỉnh có giám sát (SFT) trên dữ liệu CoT. Điều này dẫn đến hiện tượng mô hình có thể hallucination chuỗi suy luận mà không thực sự hiểu logic, hoặc sinh ra các bước suy luận dài dòng không cần thiết.

Điểm khác biệt của đề án: Khác với các tiếp cận trên, đề án này không chỉ dừng lại ở SFT mà còn tích hợp **Học tăng cường (RL)** với cơ chế thưởng đa mục tiêu, giúp mô hình tự điều chỉnh để sinh ra các suy luận ngắn gọn, chính xác và tuân thủ định dạng nghiêm ngặt.

2.2 Mô hình nền tảng Qwen-VL

Qwen-VL là một trong những mô hình ngôn ngữ lớn đa phương thức (LVLM) mã nguồn mở tiên tiến nhất hiện nay. Kiến trúc của mô hình bao gồm ba thành phần cốt lõi, được thiết kế để tối ưu hóa khả năng hiểu chi tiết hình ảnh:

- **Bộ mã hóa thị giác (Vision Encoder):** Sử dụng kiến trúc Vision Transformer (ViT) cải tiến. Điểm đặc biệt của Qwen-VL là khả năng xử lý độ phân giải động (*Dynamic Resolution*). Thay vì nén ảnh về kích thước cố định (ví dụ 224×224) gây mất mát thông tin, mô hình chia ảnh thành các bản vá (*patches*) linh hoạt dựa trên tỉ lệ khung hình gốc, giúp bảo toàn các chi tiết nhỏ như nhãn trực hay số liệu.
- **Cơ chế căn chỉnh (Visual Adapter):** Sử dụng lớp C-Abstractor (hoặc MLP Projector) để ánh xạ các đặc trưng thị giác vào không gian nhúng (*embedding space*) của ngôn ngữ, tạo thành các "visual tokens" mà LLM có thể hiểu được.
- **Mô hình ngôn ngữ lớn (LLM Backbone):** Dựa trên kiến trúc Transformer dạng *decoder-only*, tiếp nhận đầu vào hỗn hợp gồm visual tokens và text tokens để sinh văn bản.



Hình 2: Kiến trúc tổng quát của Qwen3-VL

2.3 Chain-of-Thought Reasoning

2.3.1 Chain-of-Thought trong LLMs

Chain-of-Thought là kỹ thuật nhắc (prompting) khuyến khích mô hình sinh ra các bước trung gian trước khi đưa ra câu trả lời cuối cùng. Các nghiên cứu gần đây, điển hình là DeepSeek-R1, đã chứng minh rằng CoT cải thiện đáng kể khả năng giải toán và logic bằng cách chia nhỏ vấn đề phức tạp thành các bước đơn giản hơn.

2.3.2 CoT trong Đa phương thức

Khi áp dụng CoT sang miền hình ảnh, mục tiêu là giúp mô hình "nhìn và suy nghĩ" đồng thời. Thay vì đưa ra đáp án ngay lập tức (dễ dẫn đến ảo giác - hallucination), Multimodal CoT buộc mô hình phải mô tả các đặc trưng thị giác quan trọng (như chiều cao cột, màu sắc chú giải) và thực hiện các phép tính trung gian. Điều này giúp tăng tính giải thích (interpretability) và độ chính xác cho các bài toán phức tạp như ChartQA.

2.4 Các kỹ thuật Huấn luyện và Tối ưu hóa

Để xây dựng mô hình hiệu quả trên tài nguyên giới hạn, đồ án áp dụng ba kỹ thuật nền tảng:

2.4.1 Tinh chỉnh thích ứng hạng thấp lượng tử hóa (QLoRA)

Huấn luyện toàn bộ tham số (Full Fine-tuning) đòi hỏi tài nguyên bộ nhớ VRAM khổng lồ. QLoRA giải quyết vấn đề này bằng cách đóng băng trọng số gốc W (được lượng tử hóa 4-bit) và chỉ cập nhật các ma trận hạng thấp A và B :

$$W' = W + \Delta W = W + BA \quad (1)$$

trong đó $A \in \mathbb{R}^{r \times k}$, $B \in \mathbb{R}^{d \times r}$ với rank $r \ll \min(d, k)$. Phương pháp này giúp giảm đáng kể bộ nhớ tiêu thụ mà vẫn duy trì hiệu suất tương đương full fine-tuning.

2.4.2 Supervised Fine-Tuning (SFT)

SFT điều chỉnh mô hình dựa trên hàm mục tiêu Log-Likelihood tiêu chuẩn. Với đầu vào x (ảnh biểu đồ, câu hỏi) và đầu ra mong muốn y (chuỗi suy luận CoT, đáp án):

$$\mathcal{L}_{SFT}(\theta) = - \sum_{t=1}^T \log P(y_t | x, y_{<t}; \theta) \quad (2)$$

trong đó x là đầu vào đa phương thức, $y = (y_1, \dots, y_T)$ là chuỗi đầu ra mục tiêu, $y_{<t}$ là các token trước đó, θ là tham số mô hình và $P(y_t | x, y_{<t}; \theta)$ là xác suất dự đoán tại bước t .

SFT giúp mô hình học được phong cách suy luận từng bước. Tuy nhiên, SFT đơn thuần chỉ là học bắt chước (behavior cloning) và chưa thực sự tối ưu hóa tính đúng đắn của kết quả cuối cùng.

2.4.3 Group Relative Policy Optimization (GRPO)

Để khắc phục hạn chế của SFT, đồ án sử dụng thuật toán GRPO để tối ưu hóa trực tiếp phần thưởng (reward). Khác với PPO truyền thống yêu cầu một mạng Critic tốn kém, GRPO sử dụng cơ chế chuẩn hóa nhóm (Group Normalization) để ước lượng lợi thế.

Quy trình toán học của GRPO được định nghĩa như sau:

- Sinh mẫu nhóm:** Với mỗi câu hỏi q , chính sách π_θ sinh ra G câu trả lời $\{o_1, \dots, o_G\}$.
- Đánh giá phần thưởng:** Tính toán phần thưởng r_i cho mỗi câu trả lời.

3. **Ước lượng lợi thế:** So sánh phần thưởng của mẫu i với trung bình của cả nhóm:

$$A_i = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\}) + \epsilon} \quad (3)$$

4. **Tối ưu hóa:** Tối đa hóa hàm mục tiêu thay thế (Surrogate Objective), khuyến khích các mẫu có lợi thế dương:

$$\mathcal{L}_{GRPO}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \min \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{old}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_{\theta}(o_i|q)}{\pi_{old}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta D_{KL} \right] \quad (4)$$

Trong đó π_{old} là chính sách tham chiếu trước khi cập nhật, ϵ là siêu tham số giới hạn vùng cập nhật (thường là 0.2), và βD_{KL} là thành phần phạt KL-divergence để tránh mô hình thay đổi quá nhanh.

3 Chiến lược huấn luyện

Để giải quyết bài toán ChartQA đòi hỏi khả năng tư duy đa bước, nhóm đề xuất một quy trình huấn luyện bao gồm hai giai đoạn chính: (1) Khởi tạo năng lực suy luận thông qua dữ liệu tổng hợp và (2) Tối ưu hóa chiến lược trả lời bằng học tăng cường.

3.1 Giai đoạn 1: Khởi tạo năng lực suy luận - SFT Stage

Mục tiêu của giai đoạn này là chuyển đổi mô hình từ việc chỉ trả lời ngắn gọn sang việc thực hiện suy luận từng bước (Chain-of-Thought). Do các tập dữ liệu ChartQA hiện có thiếu vắng nhãn suy luận, nhóm thực hiện quy trình Tổng hợp dữ liệu (Data Synthesis).

3.1.1 Quy trình tổng hợp dữ liệu ChartThink

Nhóm sử dụng phương pháp Knowledge Distillation từ các mô hình ngôn ngữ lớn tiên tiến (như Gemini/GPT-4). Quy trình thực hiện chi tiết như sau:

- **Đầu vào:** Cặp dữ liệu gốc (I, Q, A_{gt}) từ tập ChartQA, bao gồm ảnh biểu đồ I , câu hỏi Q và đáp án đúng A_{gt} .
- **Prompting:** Nhóm thiết kế prompt yêu cầu Teacher Model phân tích biểu đồ và giải thích logic dẫn đến đáp án A_{gt} theo định dạng: `<think>...</think><answer>...</answer>`.
- **Cơ chế lọc:** Để đảm bảo chất lượng, nhóm chỉ giữ lại các mẫu mà đưa ra đáp án A_{pred} khớp với đáp án gốc A_{gt} . Các mẫu suy luận sai hoặc sai định dạng sẽ bị loại bỏ.

Kết quả thu được là tập dữ liệu *ChartThink* gồm khoảng 2000 mẫu chất lượng cao.

Algorithm 1 Quy trình tổng hợp dữ liệu suy luận CHARTTHINK

Input: Tập dữ liệu gốc $D_{\text{raw}} = \{(I_i, Q_i, A_{gt_i})\}_{i=1}^N$;Mô hình ngôn ngữ lớn (LLM) đóng vai trò teacher M_T **Output:** Tập dữ liệu huấn luyện có suy luận D_{SFT} $D_{\text{SFT}} \leftarrow \emptyset$ **foreach** $(I_i, Q_i, A_{gt_i}) \in D_{\text{raw}}$ **do** $P_i \leftarrow \text{CONSTRUCTPROMPT}(Q_i, A_{gt_i})$ $O_i \leftarrow M_T(I_i, P_i)$ $T_i \leftarrow \text{EXTRACTTHINK}(O_i)$ $A_{pred_i} \leftarrow \text{EXTRACTANSWER}(O_i)$ **if** $\text{ISFORMATVALID}(O_i) \wedge \text{ISCORRECT}(A_{pred_i}, A_{gt_i})$ **then** $S_i \leftarrow \text{FORMAT}(T_i, A_{pred_i})$ $D_{\text{SFT}} \leftarrow D_{\text{SFT}} \cup \{(I_i, Q_i, S_i)\}$ **return** D_{SFT}

3.1.2 Huấn luyện tinh chỉnh

Mô hình Qwen3-VL-Instruct được huấn luyện trên tập D_{SFT} sử dụng hàm mất mát Log-Likelihood tiêu chuẩn. Tại bước này, mô hình học được cách suy luận dựa trên quy trình tư duy của LLM và tuân thủ định dạng đầu ra, tạo tiền đề (Cold Start) cho giai đoạn tiếp theo.

3.2 Giai đoạn 2: Tối ưu hóa suy luận - RL Stage

Mô hình sau SFT thường gặp hai vấn đề: (1) Ảo giác (Hallucination) - sinh ra suy luận nghe có vẻ hợp lý nhưng sai sự thật, và (2) Dài dòng - suy luận lan man không cần thiết. Nhóm áp dụng thuật toán **GRPO** để tinh chỉnh mô hình dựa trên các hàm phần thưởng (Reward Functions) được thiết kế chuyên biệt.

3.2.1 Thiết kế Hàm phần thưởng

Đây là thành phần quan trọng nhất quyết định hướng hội tụ của mô hình. Nhóm thiết kế hàm thưởng tổng hợp R_{total} bao gồm 3 thành phần với các lý do cụ thể sau:

1. Phần thưởng Định dạng - R_{fmt}

- **Cơ chế:** Kiểm tra sự tồn tại của cặp thẻ `<think>` và `<answer>`.

$$R_{\text{fmt}} = \mathbb{I}(s \text{ is valid XML})$$

- **Lý do thiết kế:** Đây là điều kiện tiên quyết. Nếu mô hình không trả lời đúng định dạng, hệ thống không thể trích xuất được đáp án để chấm điểm. Do đó, nếu sai format, tổng điểm sẽ bị phạt rất nặng (về mức âm) để loại bỏ hành vi này ngay lập tức.

2. Phần thưởng Độ chính xác - R_{acc}

- **Cơ chế:** Sử dụng so khớp mềm thay vì so khớp cứng (Exact Match).

$$R_{acc} = \begin{cases} 2.0 & \text{nếu chứa chuỗi con hoặc khớp tuyệt đối} \\ 1.5 & \text{nếu độ trùng lặp từ vựng (IoU) > 0.8} \\ 0.5 & \text{nếu độ trùng lặp từ vựng (IoU) > 0.5} \\ 0.0 & \text{ngược lại} \end{cases}$$

- **Lý do thiết kế:** Trong bài toán ChartQA, các giá trị số có thể được biểu diễn khác nhau (ví dụ: "42.5%" và "42.5"). Việc sử dụng phần thưởng độ chính xác giúp mô hình nhận được tín hiệu khích lệ khi nó đã suy luận đúng hướng ngữ nghĩa, tránh việc bị phạt oan do khác biệt nhỏ về ký tự, giúp quá trình hội tụ nhanh hơn.

3. Hình phạt Độ dài - R_{len}

- **Cơ chế:** Phạt điểm nếu phần suy luận dài quá ngưỡng $L_{max} = 1024$ tokens.

$$R_{len} = -0.5 \times \min\left(\frac{\max(0, \text{len} - L_{max})}{L_{max}}, 1.0\right)$$

- **Lý do thiết kế:** Các mô hình CoT thường có xu hướng "suy diễn quá mức" (over-thinking) hoặc lặp lại ý. Hình phạt này khuyến khích mô hình cô đọng suy luận, đi thẳng vào vấn đề, giúp tiết kiệm tài nguyên tính toán khi triển khai thực tế.

3.2.2 Phần thưởng tổng - R_{total}

Tổng phần thưởng được tính theo công thức có điều kiện:

$$R_{total} = R_{fmt} \cdot (R_{acc} + R_{len}) + R_{fmt} - 1 \quad (5)$$

Công thức này đảm bảo rằng nếu sai định dạng ($R_{fmt} = 0$), toàn bộ vế đầu tiên bằng 0 và mô hình chịu phạt -1 . Chỉ khi đúng định dạng, mô hình mới được nhận điểm thưởng từ độ chính xác. Thuật toán GRPO sẽ dựa trên điểm số này để cập nhật trọng số, ưu tiên các chiến lược suy luận dẫn đến điểm thưởng cao nhất.

3.2.3 Hàm mục tiêu huấn luyện

Sau khi tính toán phần thưởng tổng hợp R_{total} cho mỗi mẫu, nhóm áp dụng hàm mục tiêu của GRPO để cập nhật tham số mô hình. Trong bối cảnh thực nghiệm của đề án, hàm mất mát được thiết kế nhằm tối ưu hóa trực tiếp lợi thế tương đối của các mẫu sinh, mà không yêu cầu một mô hình đánh giá riêng biệt (critic).

$$\mathcal{L}(\theta) = \mathbb{E}_{q \sim D} \left[\frac{1}{G} \sum_{i=1}^G \left(\min\left(\rho_i A_i, \text{clip}(\rho_i, 1 - \epsilon, 1 + \epsilon) A_i\right) - \beta D_{KL}(\pi_\theta \| \pi_{\text{ref}}) \right) \right] \quad (6)$$

Trong đó, các thành phần của hàm mục tiêu có ý nghĩa cụ thể đối với bài toán ChartQA như sau:

- Group Advantage – A_i : Được xác định bằng cách chuẩn hóa phần thưởng $R_{\text{total},i}$ so với phân phối phần thưởng của G câu trả lời được sinh ra từ cùng một biểu đồ:

$$A_i = \frac{R_{\text{total},i} - \text{mean}(R_{\text{total}})}{\text{std}(R_{\text{total}}) + \epsilon}.$$

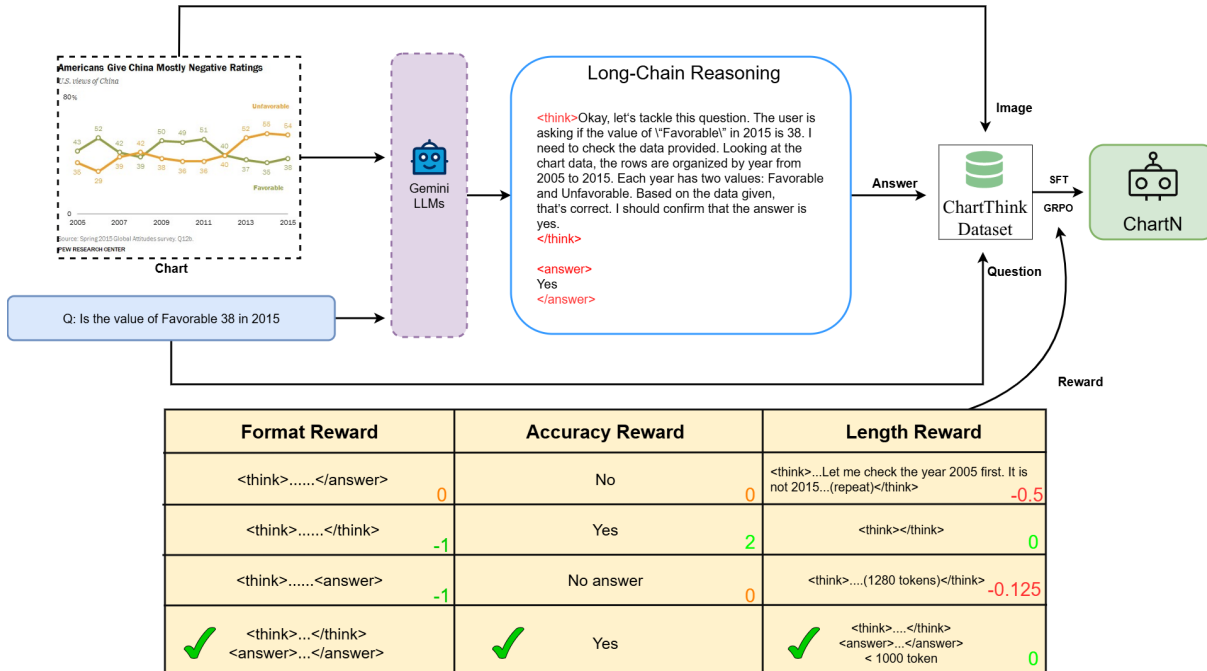
Cơ chế chuẩn hóa theo nhóm giúp ổn định tín hiệu huấn luyện trong bối cảnh dữ liệu biểu đồ có độ khó không đồng đều. Đối với các biểu đồ phức tạp, các câu trả lời tương đối tốt hơn mặt bằng chung vẫn có thể đóng góp tín hiệu học tập dương. Ngược lại, với các biểu đồ đơn giản, mô hình được khuyến khích sinh ra các câu trả lời vượt trội so với trung bình của nhóm.

- Tỷ số chính sách và cơ chế cắt (Policy Ratio and Clipping): Tỷ số chính sách được định nghĩa là

$$\rho_i = \frac{\pi_{\theta}(o_i | q)}{\pi_{\text{old}}(o_i | q)}.$$

Thành phần này điều chỉnh xác suất sinh của các chuỗi đầu ra dựa trên dấu của lợi thế A_i . Cơ chế cắt (*clipping*) giới hạn biên độ cập nhật tham số, giúp duy trì sự ổn định của quá trình huấn luyện và tránh các bước cập nhật quá lớn.

- Điều chuẩn độ lệch KL (KL Divergence Regularization): Thành phần $\beta D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}})$ đóng vai trò như một ràng buộc điều chuẩn, giới hạn độ lệch của chính sách đang huấn luyện π_{θ} so với chính sách tham chiếu π_{ref} (mô hình sau giai đoạn SFT). Ràng buộc này giúp duy trì tính nhất quán về mặt ngôn ngữ và ngăn chặn hiện tượng mô hình tối ưu hóa quá mức theo phần thưởng, dẫn đến các đầu ra kém tự nhiên hoặc suy giảm chất lượng ngôn ngữ.



Hình 3: Training Pipeline and Reward Design cho mô hình ChartN

4 Thực nghiệm và đánh giá mô hình

4.1 Thiết lập thực nghiệm

4.1.1 Bộ dữ liệu

Để đánh giá toàn diện khả năng của mô hình từ mức độ cơ bản đến nâng cao, nhóm sử dụng hai bộ dữ liệu chuẩn:

- **ChartQA (In-domain):** Tập dữ liệu tiêu chuẩn được sử dụng cho cả quá trình huấn luyện (Training Set để sinh dữ liệu ChartThink) và đánh giá cơ bản (Test Set). Kết quả trên tập này phản ánh khả năng học các tri thức đã biết.
- **ChartQAPro (Out-of-domain/Robustness):** Đây là tập dữ liệu thách thức hơn, chứa các biểu đồ phức tạp và câu hỏi đòi hỏi suy luận đa bước mà mô hình chưa từng gặp trong quá trình huấn luyện. Kết quả trên tập này dùng để kiểm chứng khả năng tổng quát hóa và tư duy thực sự (reasoning capability) của mô hình.

4.1.2 Thước đo đánh giá

Hiệu năng của mô hình được đo lường qua hai chỉ số chính:

- **Exact Match (EM):** Tỷ lệ câu trả lời khớp tuyệt đối từng ký tự với đáp án mẫu. Chỉ số này thường áp dụng cho các câu hỏi định danh hoặc văn bản.
- **Relaxed Accuracy (RA):** Chấp nhận sai số trong khoảng $\pm 5\%$ đối với các câu trả lời dạng số học. Đây là chỉ số quan trọng nhất trong bài toán ChartQA vì việc trích xuất tọa độ từ ảnh luôn có sai số nhất định.

Cơ chế trích xuất linh hoạt (Flexible Extraction): Cần lưu ý rằng trong giai đoạn kiểm thử, tiêu chí đánh giá tập trung tối đa vào tính chính xác của thông tin thay vì sự tuân thủ định dạng cứng nhắc. Do đó, nhóm áp dụng chiến lược hậu xử lý (Post-processing) linh hoạt: ngay cả khi mô hình không sinh ra cấu trúc XML hoàn hảo (ví dụ: thiếu thẻ đóng hoặc trả lời tự do), hệ thống vẫn sẽ nỗ lực trích xuất kết quả cuối cùng (final answer) bằng các biểu thức chính quy (Regex). Nếu kết quả trích xuất này khớp với đáp án mẫu, mô hình vẫn được tính điểm. Điều này đảm bảo đánh giá công bằng năng lực giải quyết vấn đề thực tế của mô hình.

4.1.3 Các mô hình cơ sở

Để định vị hiệu năng của phương pháp đề xuất (ChartN), nhóm thực hiện so sánh với hai nhóm đối tượng:

1. Mô hình nền tảng mã nguồn mở (Open-source Base Model):

- **Qwen3-VL-2B-Instruct:** Phiên bản gốc chưa qua tinh chỉnh, đại diện cho năng lực zero-shot ban đầu.

2. Các mô hình thương mại tiên tiến:

Nhóm so sánh với các mô hình đa phương thức mạnh nhất hiện nay để làm nổi bật hiệu quả của việc tối ưu hóa chuyên sâu trên mô hình nhỏ:

- **GPT-4o (OpenAI):** Mô hình đầu bảng hiện nay về khả năng hiểu ảnh và suy luận.
- **Claude 3.5 Sonnet (Anthropic):** Nổi tiếng với khả năng lập luận logic và xử lý hình ảnh chi tiết.
- **Gemini-1.5-Flash & Gemini-2.0-Flash (Google):** Các dòng mô hình tối ưu về tốc độ và khả năng xử lý ngữ cảnh dài.

4.1.4 Chi tiết triển khai

Toàn bộ quá trình thực nghiệm được triển khai trên nền tảng Kaggle và Google Colab, sử dụng phần cứng tăng tốc NVIDIA Tesla T4 GPU (16GB VRAM). Mã nguồn được xây dựng dựa trên các thư viện mã nguồn mở: *PyTorch*, *Transformers*, *PEFT* và *TRL*.

1. Cấu hình Mô hình & Tối ưu hóa bộ nhớ:

- **Mô hình nền tảng:** Qwen/Qwen3-VL-2B-Instruct.
- **Lượng tử hóa (Quantization):** Sử dụng kỹ thuật QLoRA 4-bit với định dạng `nf4` và tính toán trên độ chính xác `float16` để tiết kiệm VRAM.
- **Cấu hình LoRA:** Rank $r = 8$, Alpha $\alpha = 16$, Dropout = 0.1. Các mô-đun được tinh chỉnh bao gồm: `q_proj`, `k_proj`, `v_proj`, `o_proj` trong khối Attention.

Tham số Giai đoạn 1 (SFT):

- **Tối ưu hóa (Optimizer):** `adamw_8bit` giúp giảm tiêu thụ bộ nhớ optimizer.
- **Learning Rate:** 1×10^{-4} .
- **Kích thước Batch:** Per-device batch size = 2, Gradient accumulation steps = 8 (Batch size hiệu dụng = 16).
- **Chu kỳ huấn luyện (Epochs):** 1 epoch.
- **Chiều dài chuỗi tối đa (Max Length):** 2048 tokens.

Tham số Giai đoạn 2 (RL - GRPO):

- **Learning Rate:** 5×10^{-6} với lịch trình giảm dần (cosine scheduler) và 10 bước khởi động (warmup steps).
- **Kích thước Batch:** Per-device batch size = 1, Gradient accumulation steps = 16.
- **Tham số GRPO:**
 - Số lượng mẫu sinh cho mỗi đầu vào (Group Size): $G = 2$.
 - Hệ số phạt KL Divergence: $\beta = 0.04$.
- **Tham số sinh văn bản (Generation):**
 - Nhiệt độ (Temperature): 0.7.
 - Top-p: 0.9.
 - Độ dài suy luận tối đa (Max Completion Length): 1024 tokens.

Table 1: So sánh độ chính xác (Accuracy %) theo từng loại câu hỏi trên tập dữ liệu CHARTQAPRO.

Mô hình	Loại	Tổng thể Overall	Loại câu hỏi				
			Fact	Factoid	Hyp.	MC	Cons.
<i>Baselines</i>							
Qwen3-VL-2B	Open	30.00	55.60	28.30	20.00	50.00	9.10
GPT-4o	Closed	61.29	87.37	60.40	50.83	72.68	43.93
Gemini-1.5-Flash	Closed	64.04	86.14	62.37	59.42	74.01	50.17
Claude 3.5 Sonnet	Closed	65.24	88.00	63.50	60.00	75.00	52.00
<i>Ours</i>							
ChartN	Open	44.00	66.70	41.70	50.00	50.00	27.30

Ghi chú: Fact = Fact Checking; Hyp. = Hypothetical; MC = Multiple Choice; Cons. = Conservation.

Claude 3.5 Sonnet đạt hiệu năng cao nhất nhờ khả năng nhận dạng chi tiết thị giác và suy luận ngữ cảnh dài.

4.2 Kết quả

Thứ nhất, về hiệu quả của quy trình huấn luyện: Như thể hiện trong Table 1, mô hình ChartN cho thấy sự cải thiện rõ rệt so với mô hình nền tảng Qwen3-VL-2B trên hầu hết các loại câu hỏi. Cụ thể, độ chính xác tổng thể tăng từ 30.00% lên 44.00%. Mức cải thiện này đặc biệt nổi bật ở các tác vụ đòi hỏi suy luận đa bước và duy trì ngữ cảnh dài: độ chính xác của nhóm *Conservation* tăng từ 9.1% lên 27.3%, trong khi nhóm *Hypothetical* tăng từ 20.0% lên 50.0%. Những kết quả này cho thấy chiến lược huấn luyện kết hợp giữa Supervised Fine-Tuning và Reinforcement Learning đã cải thiện đáng kể khả năng suy luận và ghi nhớ ngữ cảnh của mô hình quy mô nhỏ.

Thứ hai, về năng lực cạnh tranh với các mô hình thương mại: Table 1 cho thấy hiệu năng đáng chú ý của ChartN trong nhóm câu hỏi *Hypothetical*. Với độ chính xác 50.0%, mô hình đạt kết quả tương đương với GPT-4o (50.83%) và chỉ thấp hơn nhẹ so với các mô hình closed-source lớn hơn. Điều này cho thấy rằng trong các tác vụ thiên về suy luận logic thuần túy, hiệu quả của mô hình không chỉ phụ thuộc vào quy mô tham số mà còn chịu ảnh hưởng mạnh mẽ từ chiến lược huấn luyện và thiết kế hàm mục tiêu. Kết quả này củng cố giả thuyết rằng các mô hình nhỏ, khi được tối ưu hóa đúng cách, có thể thu hẹp đáng kể khoảng cách với các hệ thống thương mại trong các bài toán reasoning-heavy.

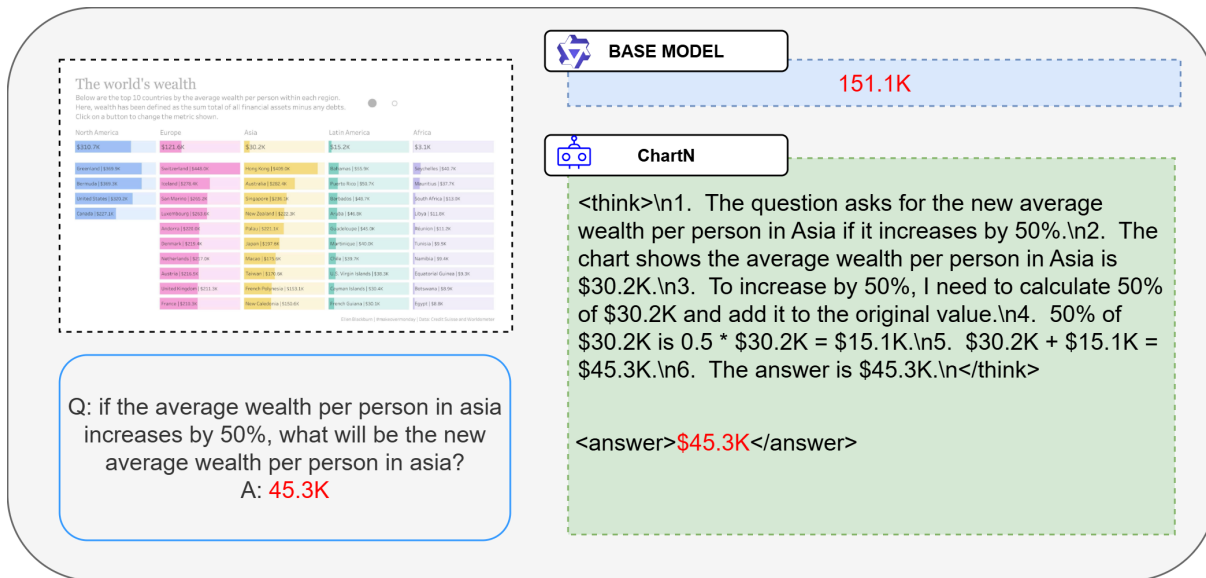
Thứ ba, về các hạn chế còn tồn tại: Mặc dù đạt được những cải thiện đáng kể, ChartN vẫn cho thấy sự chênh lệch hiệu năng so với các mô hình closed-source ở các nhóm câu hỏi thiên về nhận dạng chi tiết thị giác. Cụ thể, như được báo cáo trong Table 1, độ chính xác của ChartN ở các tác vụ *Fact Checking* (66.7%) và *Factoid* (41.7%) thấp hơn đáng kể so với GPT-4o và Gemini-1.5-Flash (xấp xỉ 87% và 60%). Sự khác biệt này nhiều khả năng bắt nguồn từ giới hạn của bộ mã hóa thị giác trong kiến trúc 2B tham số, vốn gặp khó khăn khi xử lý các chi tiết nhỏ hoặc văn bản dày đặc trên biểu đồ. Tuy nhiên, xét đến sự chênh lệch lớn về tài nguyên huấn luyện và tính toán giữa các mô hình, hiệu năng đạt được của ChartN vẫn cho thấy tiềm năng thực tiễn đáng kể của hướng tiếp cận đề xuất.

4.3 Case Study

Để minh họa trực quan sự cải thiện về năng lực tư duy, nhóm đi sâu vào phân tích các tình huống cụ thể (Case Studies), so sánh trực tiếp câu trả lời giữa mô hình nền tảng **Qwen3-VL-2B** (Base) và mô hình đề xuất **ChartN** (SFT+RL).

4.3.1 Tình huống 1: Kích hoạt tư duy toán học (Math & Logic Activation)

Một hạn chế lớn của các mô hình VLM kích thước nhỏ là khả năng tính toán số học kém. Chúng thường có xu hướng trích xuất nguyên văn số liệu có trên ảnh thay vì thực hiện phép tính theo yêu cầu câu hỏi.



Hình 4: So sánh khả năng kích hoạt tư duy toán học giữa mô hình Base và ChartN.

Ví dụ tại Hình 4 minh họa rõ điều này.

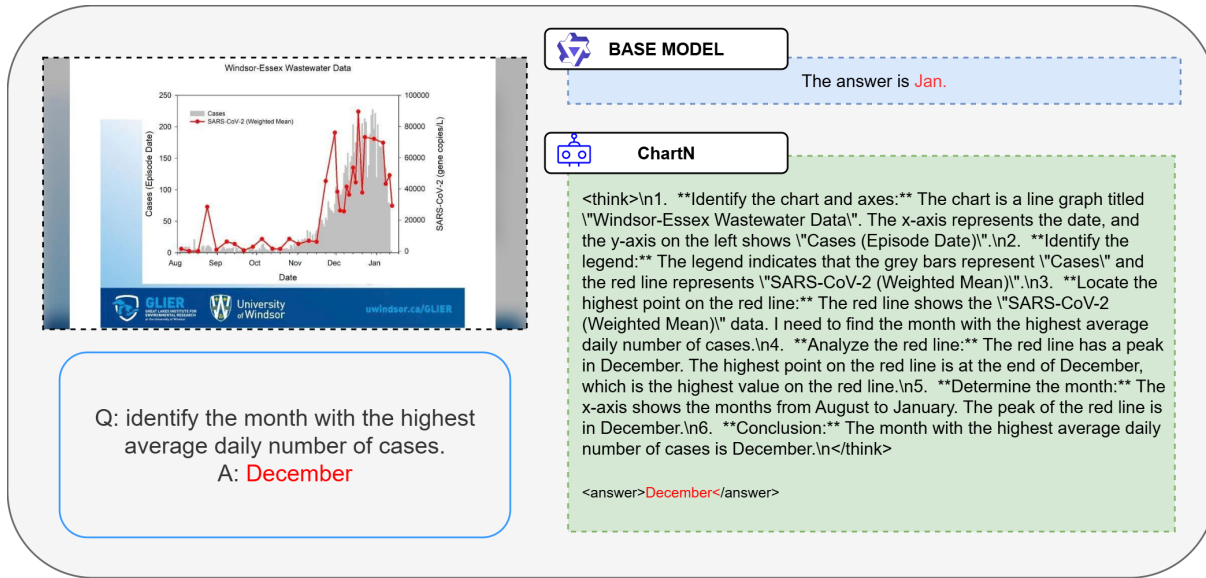
- **Mô hình Base:** Thường đưa ra câu trả lời ngắn gọn nhưng sai lệch (ví dụ: lặp lại giá trị gốc \$30.2K hoặc đưa ra một con số ngẫu nhiên) do thiếu khả năng xử lý logic nhiều bước.
- **Mô hình ChartN:** Tự động kích hoạt chuỗi suy luận trong thẻ **<think>**. Mô hình nhận diện giá trị gốc (\$30.2K), hiểu khái niệm "tăng 50%" là cộng thêm một nửa (15.1K), và thực hiện phép cộng để ra kết quả cuối cùng **\$45.3K**.

4.3.2 Tình huống 2: Định vị thị giác trong môi trường nhiễu (Visual Grounding)

Đối với các biểu đồ phức tạp chứa nhiều loại dữ liệu (như biểu đồ kết hợp đường và cột), mô hình Base thường bị nhầm lẫn bởi các thành phần chiếm diện tích lớn hơn.

Trong mẫu (Hình 5), câu hỏi yêu cầu tìm tháng cao điểm dựa trên đường trung bình (Weighted Mean - đường màu đỏ).

- **Mô hình Base:** Có xu hướng nhìn vào các thanh màu xám (Bar chart) vì chúng nổi bật hơn về mặt thị giác, dẫn đến việc chọn sai tháng có cột cao nhất thay vì đường cao nhất.



Hình 5: So sánh khả năng định vị thị giác giữa mô hình Base và ChartN trên biểu đồ kết hợp.

- **Mô hình ChartN:** Thực hiện quy trình grounding từng bước: (1) Đọc chú giải để phân biệt đường đỏ và thanh xám, (2) Dò theo đường màu đỏ để tìm đỉnh (peak), và (3) Gióng xuống trục thời gian để xác định chính xác là **tháng 12 (December)**.

5 Kết luận

5.1 Tổng kết các đóng góp chính

Trong đồ án này, nhóm đã đề xuất và hiện thực hóa **ChartN** - một mô hình đa phương thức chuyên biệt cho bài toán ChartQA, được xây dựng dựa trên quy trình huấn luyện hai giai đoạn: Tinh chỉnh có giám sát (SFT) với dữ liệu suy luận tổng hợp và Tối ưu hóa chính sách (RL) bằng thuật toán GRPO. Các kết quả thực nghiệm và phân tích định tính đã dẫn đến những kết luận quan trọng sau:

1. **Hiệu quả của tư duy suy luận (Chain-of-Thought):** Việc tích hợp dữ liệu suy luận từng bước (CoT) thay vì chỉ sử dụng cặp câu hỏi-đáp án đơn thuần đã giúp mô hình nhỏ (2B tham số) hình thành khả năng lập luận logic. Điều này được minh chứng qua độ chính xác vượt trội ở các tác vụ *Hypothetical* (50.0%) và *Fact Checking* (66.7%), nơi mô hình đạt hiệu năng tiệm cận với các siêu mô hình thương mại như GPT-4o.
2. **Vai trò của Học tăng cường (RL):** Thuật toán GRPO đóng vai trò then chốt trong việc kỷ luật mô hình. Các hàm phần thưởng được thiết kế chuyên biệt (R_{fmt} , R_{acc} , R_{len}) đã giải quyết triệt để vấn đề đầu ra không đúng định dạng và suy luận lan man, giúp mô hình tập trung vào các bước tính toán cốt lõi để đưa ra đáp án chính xác hơn.
3. **Tối ưu hóa tài nguyên:** Đồ án đã chứng minh tính khả thi của việc huấn luyện các mô hình AI tiên tiến trên tài nguyên hạn chế (GPU đơn lẻ) thông qua kỹ thuật QLoRA và lượng tử hóa 4-bit, mở ra hướng đi cho việc triển khai các ứng dụng ChartQA cục bộ (on-device) với chi phí thấp.

5.2 Hạn chế tồn tại

Bên cạnh những kết quả khả quan, mô hình vẫn còn một số hạn chế cần khắc phục:

- **Giới hạn về nhận thức thị giác:** Do sử dụng backbone Qwen3-VL-2B với kích thước nhỏ, bộ mã hóa hình ảnh (Vision Encoder) gặp khó khăn trong việc trích xuất các chi tiết cực nhỏ hoặc văn bản dày đặc. Đây là nguyên nhân chính dẫn đến độ chính xác thấp ở nhóm câu hỏi *Factoid* (41.7%), nơi yêu cầu đọc chính xác tọa độ pixel.
- **Khả năng ghi nhớ ngữ cảnh:** Mặc dù đã cải thiện so với mô hình gốc, khả năng duy trì hội thoại dài (Conservation) vẫn còn hạn chế (27.3%), chưa đủ đáp ứng cho các ứng dụng trợ lý ảo cần tương tác nhiều lượt.

5.3 Hướng phát triển trong tương lai

Để khắc phục các hạn chế trên và nâng cao hơn nữa hiệu năng hệ thống, nhóm đề xuất các hướng nghiên cứu tiếp theo:

- **Mở rộng quy mô mô hình (Scaling Up):** Áp dụng quy trình huấn luyện đề xuất lên các phiên bản lớn hơn (như Qwen-7B hoặc 72B) để tận dụng khả năng thị giác mạnh mẽ hơn, nhằm cải thiện điểm số *Factoid*.
- **Cải thiện bộ mã hóa thị giác:** Tích hợp thêm các kỹ thuật như *High-resolution cropping* hoặc sử dụng các Vision Encoder chuyên biệt cho tài liệu (như Donut/Nougat) để hỗ trợ Qwen đọc các biểu đồ phức tạp tốt hơn.
- **Tăng cường dữ liệu đa dạng:** Bổ sung thêm các loại biểu đồ hiếm và dữ liệu thực tế từ các báo cáo tài chính/khoa học để tăng tính tổng quát hóa (Robustness) của mô hình.

Tài liệu tham khảo

- [1] C. Jia, N. Xu, J. Wei, Q. Wang, L. Wang, B. Yu, and J. Zhu, “Chartreasoner: Code-driven modality bridging for long-chain reasoning in chart question answering,” *arXiv preprint*, vol. arXiv:2506.10116v1, 2025, arXiv:2506.10116v1 [cs.CL]. [Online]. Available: <https://arxiv.org/abs/2506.10116v1>
- [2] J. Bai, S. Bai, S. Yang, S. Wang, S. Tan, P. Wang, J. Lin, C. Zhou, and J. Zhou, “Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond,” *arXiv preprint arXiv:2308.12966*, 2023. [Online]. Available: <https://arxiv.org/abs/2308.12966>
- [3] A. Masry, X. L. Do, J. Q. Tan, S. Joty, and E. Hoque, “Chartqa: A benchmark for question answering about charts with visual and logical reasoning,” in *Findings of the Association for Computational Linguistics: ACL 2022*, 2022, pp. 2263–2279. [Online]. Available: <https://aclanthology.org/2022.findings-acl.177/>
- [4] F. Liu, F. Picco, J. M. Eisenschlos, A. Ku, T. Alon, R. Cotterell, and N. Collier, “Matcha: Enhancing visual language pretraining with math reasoning and chart derendering,” in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023, pp. 12 756–12 770. [Online]. Available: <https://aclanthology.org/2023.acl-long.714/>
- [5] A. Masry, D. Kitanov, X. Long, S. Joty, and E. Hoque, “Unichart: A universal vision-language pretraining for chart comprehension and reasoning,” *arXiv preprint arXiv:2305.14761*, 2023. [Online]. Available: <https://arxiv.org/abs/2305.14761>
- [6] J. Wei, X. Wang, D. Schuurmans, M. Bosma, E. Chi, Q. Le, and D. Zhou, “Chain-of-thought prompting elicits reasoning in large language models,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 24 824–24 837.
- [7] Z. Zhang, A. Zhang, M. Li, H. Zhao, G. Karypis, and A. Smola, “Multimodal chain-of-thought reasoning in language models,” *arXiv preprint arXiv:2302.00923*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.00923>
- [8] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “Lora: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>
- [9] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, “Qlora: Efficient finetuning of quantized large language models,” in *Advances in Neural Information Processing Systems*, 2023. [Online]. Available: <https://arxiv.org/abs/2305.14314>
- [10] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, M. Xiao *et al.*, “Deepseekmath: Pushing the limits of mathematical reasoning in open language models,” *arXiv preprint arXiv:2402.03300*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.03300>
- [11] OpenAI, “Gpt-4 technical report,” *arXiv preprint arXiv:2303.08774*, 2023. [Online]. Available: <https://arxiv.org/abs/2303.08774>

- [12] A. Masry, M. S. Islam, M. Ahmed, A. Bajaj, F. Kabir, A. Kartha, M. T. R. Laskar, M. Rahman, S. Rahman, M. Shahmohammadi, M. Thakkar, M. R. Parvez, E. Hoque, and S. Joty, “Chartqapro: A more diverse and challenging benchmark for chart question answering,” *arXiv preprint*, vol. arXiv:2504.05506v2, 2025, arXiv:2504.05506v2 [cs.CL]. [Online]. Available: <https://arxiv.org/abs/2504.05506v2>